

# Отчет по классификации открытых/закрытых глаз

Мельникова Елена

17 сентября 2024 г.

## 1 Постановка задачи

Требуется обучить классификатор открытых/закрытых глаз с использованием предоставленной обучающей выборки.

## 2 Кластеризация

Обучающая выборка не содержала меток классов открытых или закрытых глаз. Для решения данной задачи было принято решение применить кластеризацию для предварительной разметки данных.

Для извлечения признаков из изображений глаз были использованы Dlib и VGG-Face<sup>1</sup>. Модель VGG-Face была разработана специально для задач распознавания лиц и является адаптацией архитектуры VGG для работы с изображениями лиц. Она обучена на большом наборе данных лиц и демонстрирует отличные результаты при распознавании лиц. Библиотека Dlib содержит предобученную модель для распознавания лиц, которая использует ResNet архитектуру для извлечения признаков. Модель обучена на большом наборе данных лиц и может использоваться для задач идентификации и верификации.

Эти модели были выбраны, поскольку они обучены на изображениях лиц и, вероятно, могут эффективно извлекать признаки, связанные с глазами. Для оценки качества кластеризации была вычислена метрика `Silhouette_score`.

---

<sup>1</sup><https://github.com/serengil/deepface>

Метод кластеризации	Dlib	VGG-Face
KMeans	0.0863	<b>0.1136</b>
AgglomerativeClustering	0.0621	0.0969
DBSCAN	0.0606	0.0356
BisectingKMeans	0.0873	<b>0.1093</b>

Таблица 1: Silhouette\_score для разных кластеризаторов и фичей

Как видно из таблицы, алгоритмы, работающие с признаками, извлеченными с помощью модели VGG-Face, показали лучшие результаты. Наиболее эффективными оказались BisectingKMeans и KMeans.




Рис. 1: Пример кластеризации KMeans на признаках от Dlib. Видно, что некоторые изображения были размечены некорректно, но в большинстве случаев результат правильный.

Для повышения качества кластеризации была использована библиотека Optuna для подбора гиперпараметров лучших моделей кластеризации BisectingKMeans и KMeans. Оптимизация позволила незначительно улучшить метрику.




Рис. 2: Визуализация лучших алгоритмов кластеризации.

Для улучшения качества разметки датасета были выбрали семплы, по которым все хорошие модели (все, кроме DBSCAN на VGG-Face фичах) кластеризации дали одинаковый результат. После фильтрации датасета по согласованным результатам метрика улучшилась до 0.22, что в два

раза превышает показатель лучшей модели кластеризации с оптимизированными гиперпараметрами. Однако размер отфильтрованного датасета составил лишь четверть от исходного объема данных (около 1000 семплов).




Рис. 3: Итоговое разбиение по согласованным результатам

Был также опробован выбор наиболее частого предсказания среди предсказаний всех моделей, однако такая кластеризация по метрике оказалась хуже, чем KMeans кластеризация.

### 3 Классификация

Для классификации в качестве бекбона использовалась модель InceptionResnetV1<sup>2</sup>, предобученная на vggface2, так как она показала высокую эффективность в задачах классификации лиц. Решила не брать те же сети, что и для кластеризации, чтобы увеличить вероятность отловить ошибки в полученной разметке. Финальный слой был заменен на линейный с двумя выходными классами. Все веса модели были разморожены для обучения (Были проведены эксперименты с замороженными весами, но лучшие результаты удалось получить при полной разморозке). В качестве функции потерь использовалась кросс-энтропия (классы сбалансированы).

```
Train: 65340 images
Validation: 16335 images
Test: 16335 images
INFO:pytorch_lightning.callbacks.model_summary:
| Name | Type | Params | Mode
-----|-----|-----|-----
0 | model | EyesClassifier | 23.5 M | train
-----|-----|-----|-----
23.5 M | Trainable params
0 | Non-trainable params
23.5 M | Total params
93.935 | Total estimated model params size (MB)
552 | Modules in train mode
0 | Modules in eval mode

Epoch 0, Val_loss: 0.73751 Val_eer: 0.65289

Epoch 0, Val_loss: 0.05901 Val_eer: 0.01156

Epoch 0, Train_loss: 0.06529 Train_eer: 0.02278

Epoch 1, Val_loss: 0.06029 Val_eer: 0.01731

Epoch 1, Train_loss: 0.02994 Train_eer: 0.00928

Epoch 2, Val_loss: 0.03074 Val_eer: 0.00955

Epoch 2, Train_loss: 0.02641 Train_eer: 0.00841
```

Рис. 4: Обучение на датасете с Kaggle

#### 3.1 Обучение на внешнем датасете

Поскольку исходный датасет был небольшим и содержал ошибки в разметке, было решено использовать внешний размеченный датасет с Kaggle<sup>3</sup>.

<sup>2</sup><https://github.com/timesler/facenet-pytorch>

<sup>3</sup><https://www.kaggle.com/datasets/tauilabdelilah/mrl-eye-dataset>

Модель обучалась на этом датасете в течение 10 эпох. Лучшая метрика EER и лосс была достигнута на 4 эпохе ( $< 0.01$  на валидации), после чего модель начала переобучаться. Лучшую модель сохранила как `kaggle_model`.

### 3.2 Обучение на маленькой выборке

Затем `kaggle_model` была дообучена на выборке, полученной после кластеризации, состоящей из 1000 семплов, которые были разделены на тренировочную и тестовую подвыборки. Был проведён сравнительный анализ инференса на тестовой выборке, используя эту модель (`best_1000`), и инференса на той же тестовой выборке моделью `kaggle_model`. Даже обычная `kaggle_model` показывала хорошие результаты ( $EER = 0.07$ ), однако допускала ошибки на изображениях с закрытыми глазами и длинными ресницами, классифицируя их как открытые. Вероятно, в открытом датасете таких семплов не было, что и привело к ошибкам. После дообучения эти ошибки исчезли.





Рис. 5: Семплы где `kaggle_model` ошибочно приняла глаз за открытый

### 3.3 Обучение на большой выборке

Затем оставшаяся часть данной мне выборки, состоящая из 3000 семплов, была размечена с помощью `best_1000` - хорошей модели, судя по метрикам на предыдущем шаге.

Изображения, для которых уверенность модели была меньше 0.05 и больше 0.95 были приняты за верные. Оставшиеся неуверенные семплы были размечены вручную (около 200). При ручной разметке стало ясно, что некоторые семплы сложно распознать даже человеку.



Получив хорошо размеченный датасет, он был разделен на трейн и тест выборку. Модель `kaggle_model` была снова дообучена, но теперь на большем датасете (из 3000 семплов). Модель `best_1000` больше не использовалась, так как с ее помощью были размечены данные. Получилась итоговая модель `final_best`. Метрика получились чуть хуже

чем на **best\_1000**, однако и данные были сложнее - так как кластеризация не смогла с ними справиться. Инференс **final\_best** на тестовой выборке для **best\_1000** показал примерно такие же результаты.

Модель	train_size	test_size	train_EER	val_EER	test_EER
kaggle_model	80.000	3000	0.002	0.01	0.02
best_1000	1131	283	0	0.01	0.02
final_best	2068	518	0.02	0.03	0.03

Таблица 2: Результаты каждой модели на своей выборке

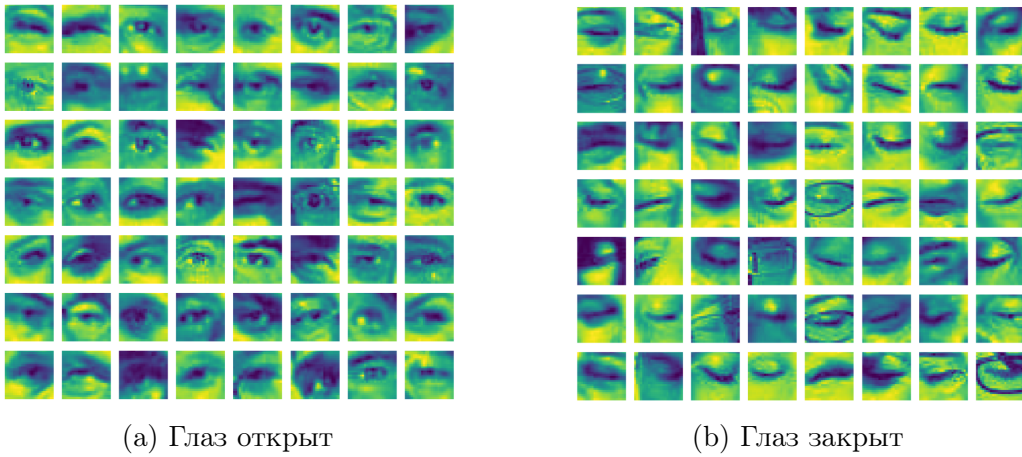


Рис. 6: Правильные предсказания **final\_best** на тестовой выборке

Также смотря на ошибки **final\_best** можно заметить, что эти случаи действительно сложные и возможно все еще остались некоторые проблемы в разметке датасета. На некоторых ошибочных предсказаниях кажется, что модель на самом деле права.




Рис. 7: Ошибочные предсказания **final\_best** на тестовой выборке